Benchmark de colors

Comparació de models amb imatges amb soroll i colors sòlids sense soroll

Resum executiu

Aquest informe compara el comportament dels models quan han d'identificar el color d'una imatge. S'analitzen dos escenaris: mostres amb soroll, on la imatge conté variabilitat visual, i mostres sense soroll, on el color és sòlid. La variable principal és l'error cromàtic, i també s'estudia el chroma i la possible concentració de respostes repetides.

En general, l'error baixa clarament quan s'eliminen els patrons de soroll. En colors sòlids, gpt-5.5 obté la mitjana d'error més baixa. En imatges amb soroll, gpt-5.1 queda com el model amb millor mitjana. El model gpt-4o-mini mostra més error i més concentració de respostes.

Control de la mostra d'entrada

Abans d'analitzar les respostes dels models s'ha comprovat si la mostra d'entrada contenia repeticions. En tots dos escenaris, les 1000 imatges són úniques i els 1000 colors objectiu també són únics. Això vol dir que les repeticions observades posteriorment provenen de les respostes dels models, no de colors duplicats en l'input.

Mostra	Files	Imatges úniques	HEX únics	Dup. imatge	Dup. HEX	NA
Amb soroll	1000	1000	1000	0	0	0
Sense soroll	1000	1000	1000	0	0	0

1. Mesures utilitzades

Cada color objectiu es representa amb components RGB: *R*, *G* i *B*. La resposta del model per a la imatge *i* i el model *j* es representa com *Rhat*, *Ghat* i *Bhat*.

Error cromàtic

$$error_{ij} = \sqrt{(\hat{R}_{ij} - R_i)^2 + (\hat{G}_{ij} - G_i)^2 + (\hat{B}_{ij} - B_i)^2}$$

Aquest error es calcula com una distància euclidiana en l'espai RGB. Com més petit és el valor, més propera és la resposta del model al color real.

Chroma

$$chroma_i = \frac{\max(R_i, G_i, B_i) - \min(R_i, G_i, B_i)}{\max(R_i, G_i, B_i)}$$

El chroma pren valors entre 0 i 1. Els valors propers a 0 indiquen colors grisosos o poc saturats; els valors propers a 1 indiquen colors més saturats.

Concentració de respostes

S'ha revisat si els models repeteixen massa sovint els mateixos colors. Per això es calcula el nombre de respostes HEX úniques, la ràtio d'únics, la repetició màxima i el percentatge acumulat en les 10 respostes més repetides.

2. Resultats amb soroll

Conjunt de dades combinat: 7,000 registres, 1,000 imatges i 7 models. El model amb menor error mitjà és **gpt-5.1** (26.96).

Descriptiva de l'error cromàtic

Model	n	Mitjana	Mediana	SD
gpt-4o	1000	35.11	30.43	22.19
gpt-4o-mini	1000	60.71	54.80	33.49
gpt-5	1000	32.04	30.42	15.59
gpt-5.1	1000	26.96	24.84	13.93
gpt-5.2	1000	52.48	47.28	29.55
gpt-5.4	1000	47.62	43.77	25.05
gpt-5.5	1000	45.97	43.01	24.63

Concentració de respostes

La taula resumeix si un model tendeix a concentrar moltes imatges en poques respostes HEX. Una ràtio d'únics baixa i un top 10 alt indiquen més repeticions i, per tant, una resposta menys adaptada a cada imatge.

Model	n	HEX únics	Ràtio únics	Màx. rep.	Top 10 %
gpt-4o	1000	702	0.70	28	15.20
gpt-4o-mini	1000	369	0.37	87	33.30
gpt-5	1000	999	1.00	2	1.10
gpt-5.1	1000	984	0.98	4	2.40
gpt-5.2	1000	877	0.88	25	12.90
gpt-5.4	1000	976	0.98	12	3.40
gpt-5.5	1000	822	0.82	53	16.10

Percentatge d'encert segons llindars d'error

Model	HEX exacte	err <= 10	err <= 20	err <= 30	err <= 50
gpt-4o	0.00	5.60	26.30	49.10	80.90
gpt-4o-mini	0.00	1.20	8.00	18.30	43.10
gpt-5	0.00	5.10	23.40	48.40	87.10
gpt-5.1	0.00	7.70	35.80	64.30	93.70
gpt-5.2	0.00	1.40	8.40	22.80	54.10
gpt-5.4	0.00	2.00	10.50	24.10	59.80
gpt-5.5	0.10	2.50	13.30	26.90	62.90

Gràfics principals

Distribució de l'error cromàtic

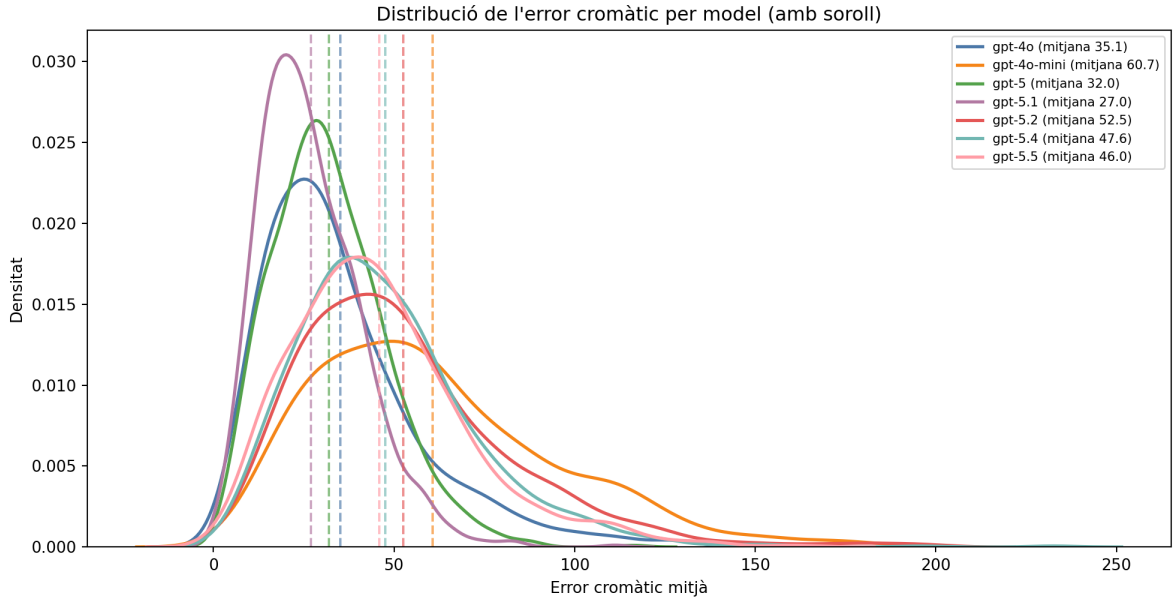

Violí i diagrama de caixa de l'error

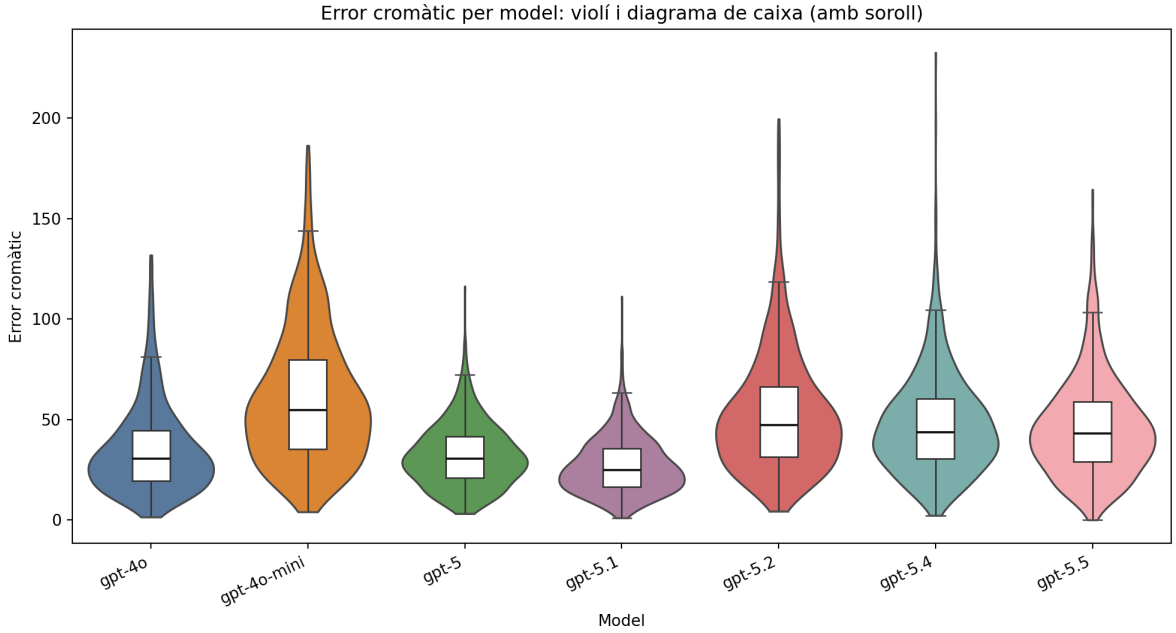

Anàlisi del chroma

El chroma mesura com de saturat o pur és el color base. En l'anàlisi preliminar s'ha revisat si els colors amb chroma alt fan augmentar l'error.

Correlació lineal entre error i chroma

Model	n	Correlació
gpt-4o	1000	0.425
gpt-4o-mini	1000	0.273
gpt-5	1000	0.336
gpt-5.1	1000	0.244
gpt-5.2	1000	0.064
gpt-5.4	1000	-0.036
gpt-5.5	1000	0.357

Error mitjà per grup de chroma

Model	Baix	Mitjà-baix	Mitjà-alt	Alt
gpt-4o	24.14	30.29	35.88	50.15
gpt-4o-mini	47.25	57.63	67.59	70.38
gpt-5	24.75	31.43	33.94	38.03
gpt-5.1	23.10	26.65	26.40	31.68
gpt-5.2	50.19	50.49	53.97	55.27
gpt-5.4	47.97	49.42	47.32	45.76
gpt-5.5	34.80	40.48	49.76	58.84

Error versus chroma

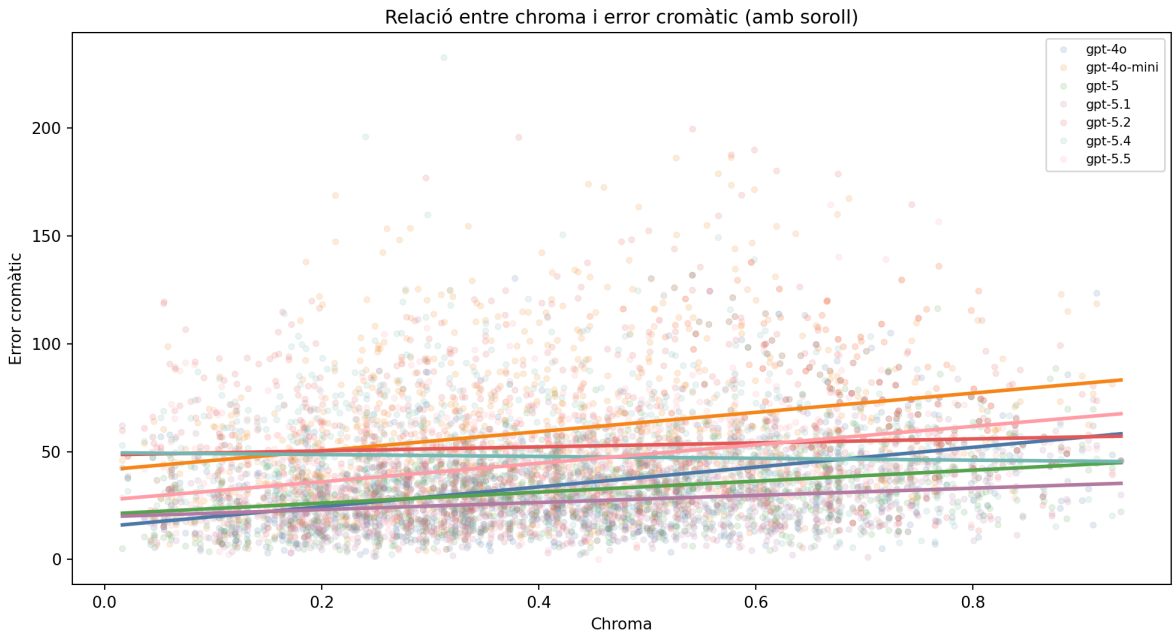

Respostes repetides

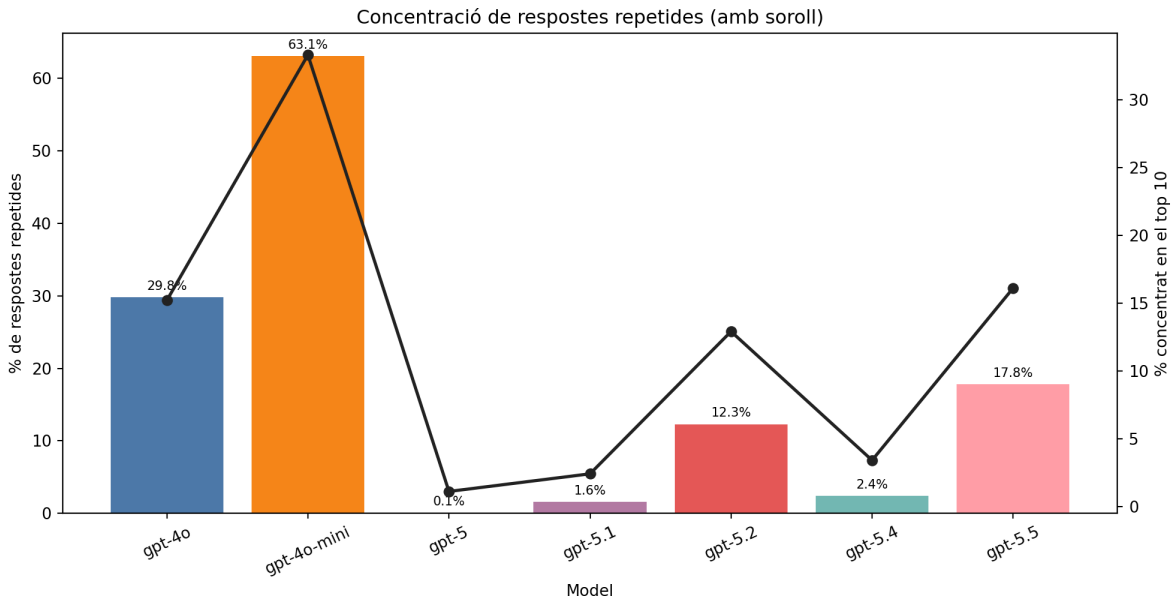

3. Resultats sense soroll

Conjunt de dades combinat: 7,000 registres, 1,000 imatges i 7 models. El model amb menor error mitjà és **gpt-5.5** (12.07).

Descriptiva de l'error cromàtic

Model	n	Mitjana	Mediana	SD
gpt-4o	1000	23.60	18.17	17.65
gpt-4o-mini	1000	49.67	41.93	32.83
gpt-5	1000	13.46	11.36	8.91
gpt-5.1	1000	16.20	13.19	11.56
gpt-5.2	1000	17.12	13.27	16.26
gpt-5.4	1000	14.29	12.61	8.84
gpt-5.5	1000	12.07	10.49	7.41

Concentració de respostes

La taula resumeix si un model tendeix a concentrar moltes imatges en poques respostes HEX. Una ràtio d'únics baixa i un top 10 alt indiquen més repeticions i, per tant, una resposta menys adaptada a cada imatge.

Model	n	HEX únics	Ràtio únics	Màx. rep.	Top 10 %
gpt-4o	1000	785	0.79	21	10.00
gpt-4o-mini	1000	418	0.42	74	26.40
gpt-5	1000	988	0.99	4	2.20
gpt-5.1	1000	977	0.98	6	2.90
gpt-5.2	1000	962	0.96	22	4.60
gpt-5.4	1000	994	0.99	3	1.60
gpt-5.5	1000	999	1.00	2	1.10

Percentatge d'encert segons llindars d'error

Model	HEX exacte	err <= 10	err <= 20	err <= 30	err <= 50
gpt-4o	0.20	21.00	54.50	73.90	90.70
gpt-4o-mini	0.00	4.90	18.70	33.50	60.00
gpt-5	0.10	42.90	80.00	94.80	99.60
gpt-5.1	0.00	35.60	72.60	87.30	98.30
gpt-5.2	0.00	33.60	75.00	89.80	96.40
gpt-5.4	0.10	36.80	77.80	93.60	99.90
gpt-5.5	0.00	46.00	85.70	97.30	100.00

Gràfics principals

Distribució de l'error cromàtic

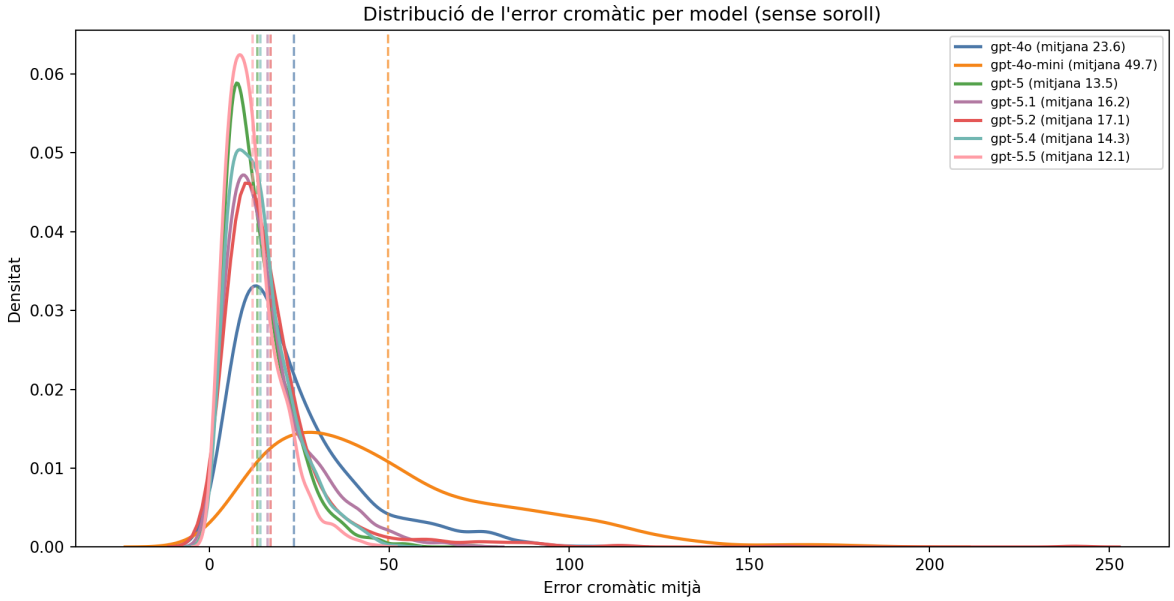

Violí i diagrama de caixa de l'error

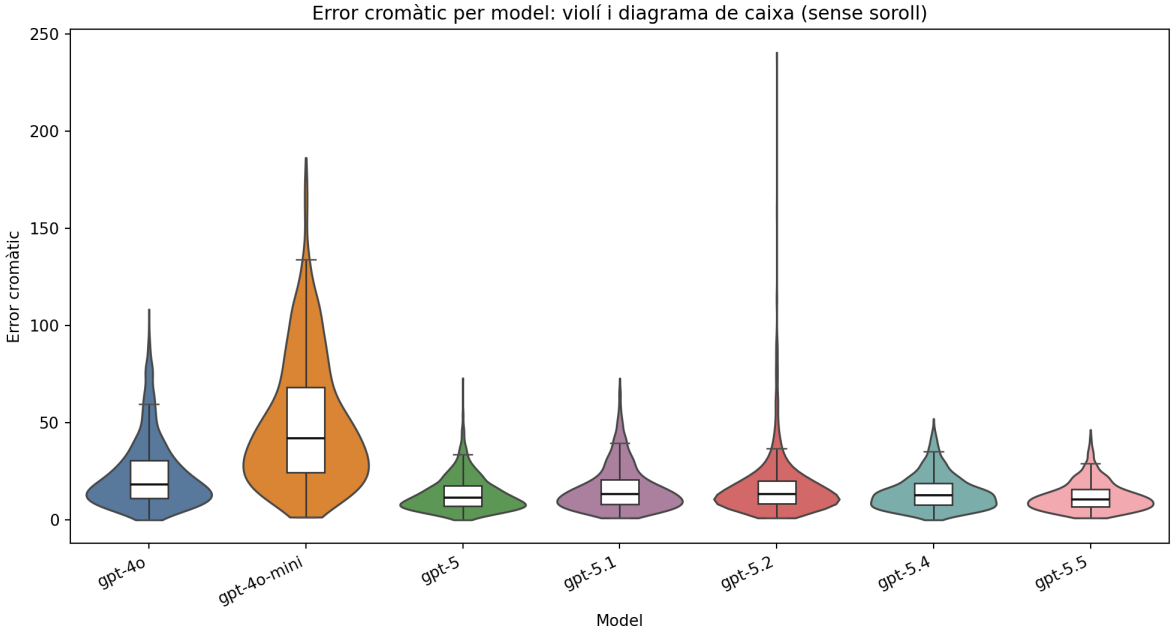

Anàlisi del chroma

El chroma mesura com de saturat o pur és el color base. En l'anàlisi preliminar s'ha revisat si els colors amb chroma alt fan augmentar l'error.

Correlació lineal entre error i chroma

Model	n	Correlació
gpt-4o	1000	0.503
gpt-4o-mini	1000	0.400
gpt-5	1000	0.523
gpt-5.1	1000	0.573
gpt-5.2	1000	0.352
gpt-5.4	1000	0.360
gpt-5.5	1000	0.222

Error mitjà per grup de chroma

Model	Baix	Mitjà-baix	Mitjà-alt	Alt
gpt-4o	14.45	17.28	24.24	38.41
gpt-4o-mini	33.42	43.91	52.05	69.31
gpt-5	8.05	11.68	13.71	20.39
gpt-5.1	9.89	12.74	15.00	27.16
gpt-5.2	12.24	11.93	16.49	27.80
gpt-5.4	10.77	12.84	14.13	19.41
gpt-5.5	9.64	12.80	11.34	14.52

Error versus chroma

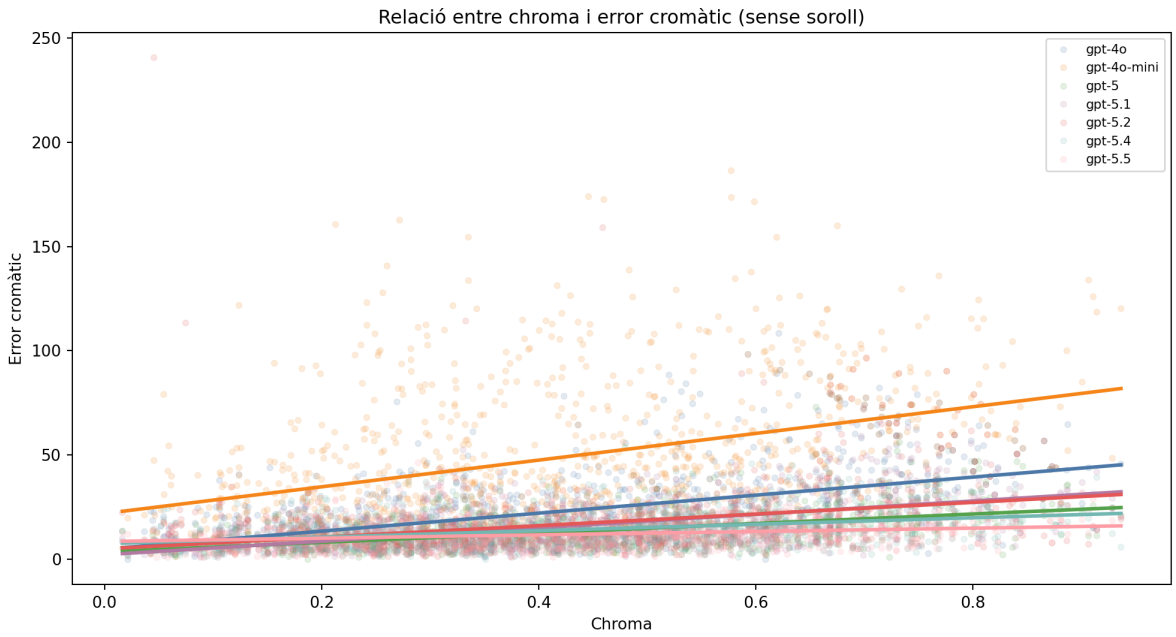

Respostes repetides

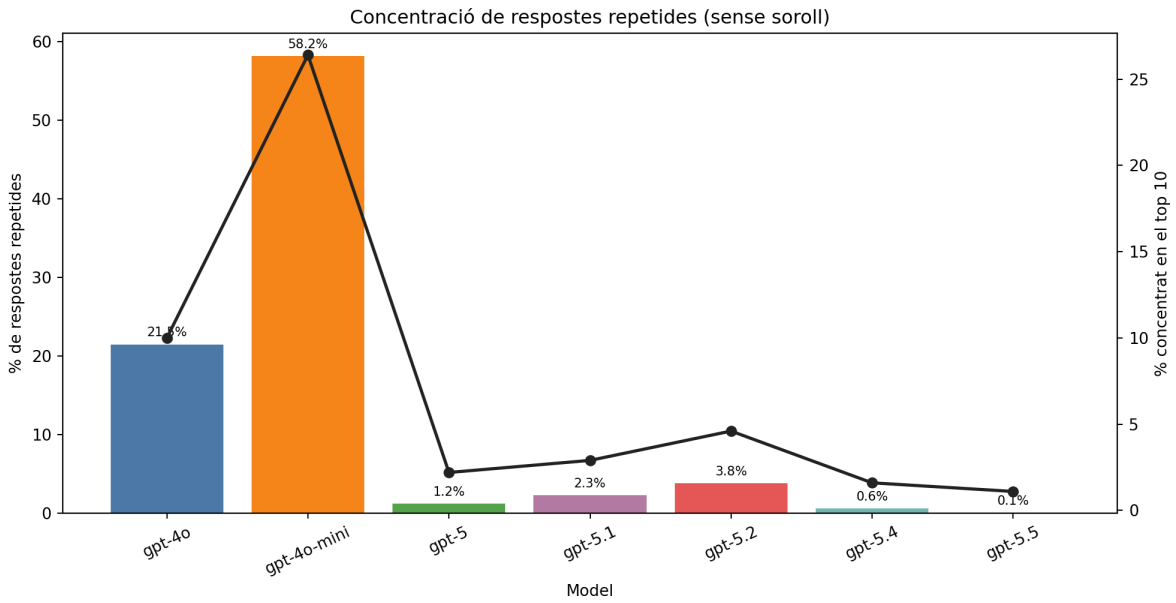

4. Comparació final

Model	Mitjana amb soroll	Mitjana sense soroll	Millora sense soroll
gpt-4o	35.11	23.60	11.52
gpt-4o-mini	60.71	49.67	11.04
gpt-5	32.04	13.46	18.58
gpt-5.1	26.96	16.20	10.76
gpt-5.2	52.48	17.12	35.37
gpt-5.4	47.62	14.29	33.33
gpt-5.5	45.97	12.07	33.90

Conclusions principals

1. L'error cromàtic baixa de manera clara en gairebé tots els models quan es passa d'imatges amb soroll a colors sòlids.

2. En l'escenari amb soroll, gpt-5.1 és el model amb menor error mitjà.

3. En l'escenari sense soroll, gpt-5.5 és el model amb menor error mitjà i també presenta un comportament competitiu en la resta d'indicadors.

4. gpt-4o-mini presenta més error i una concentració de respostes més alta, especialment en les mostres amb soroll.

5. El chroma ajuda a entendre part de la dificultat: els colors més saturats tendeixen a mostrar patrons d'error diferents segons el model.