Benchmark de colores

Comparacion de modelos con imagenes con ruido y colores solidos sin ruido

Objetivo: resumir como se ha construido la muestra, como se miden el error cromatico y el chroma, y que diferencias aparecen entre modelos y condiciones experimentales.

Resumen ejecutivo

En imagenes con ruido, el mejor error medio es de gpt-5.1. En colores solidos sin ruido, el mejor error medio pasa a gpt-5.5. Esto sugiere que el ruido cambia de forma importante la dificultad perceptiva y el ranking entre modelos.

Los modelos GPT-5 reducen mucho el lazy response frente a gpt-4o-mini. El chroma tambien importa: en general, los colores mas saturados tienden a aumentar el error.

1. Medidas usadas

Cada color objetivo se representa como RGB: (R_i, G_i, B_i). La respuesta del modelo j para la imagen i se representa como (Rhat_ij, Ghat_ij, Bhat_ij).

Error cromatico:

```
error_ij = sqrt((Rhat_ij - R_i)^2 + (Ghat_ij - G_i)^2 + (Bhat_ij - B_i)^2)
```

Un error 0 indica acierto exacto RGB. A mayor error, mayor distancia entre el color estimado y el color objetivo.

Chroma:

```
chroma_i = (max(R_i, G_i, B_i) - min(R_i, G_i, B_i)) / max(R_i, G_i, B_i)
```

Si el maximo RGB es 0, se define chroma = 0. Valores cercanos a 0 son colores grisaceos o poco saturados; valores cercanos a 1 son colores muy saturados.

Lazy response:

Se evalua contando colores repetidos: colores unicos, ratio de colores unicos, maxima repeticion y porcentaje de respuestas dentro de los 10 colores mas repetidos.

2. Resultados - Con ruido

Dataset combinado: 7000 respuestas, 1000 imagenes y 7 modelos. Mejor error medio: gpt-5.1 (26.96). Modelo con mayor lazy response: gpt-4o-mini (33.3% en top 10 colores repetidos).

Descriptiva del error cromatico

Modelo	n	Media	Mediana	SD
gpt-4o	1000	35.11	30.43	22.19
gpt-4o-mini	1000	60.71	54.80	33.49
gpt-5	1000	32.04	30.42	15.59
gpt-5.1	1000	26.96	24.84	13.93
gpt-5.2	1000	52.48	47.28	29.55
gpt-5.4	1000	47.62	43.77	25.05
gpt-5.5	1000	45.97	43.01	24.63

Lazy response

Modelo	Unicos	Ratio	Max rep.	Top10 %
gpt-4o	702	0.702	28	15.20
gpt-4o-mini	369	0.369	87	33.30
gpt-5	999	0.999	2	1.10
gpt-5.1	984	0.984	4	2.40
gpt-5.2	877	0.877	25	12.90
gpt-5.4	976	0.976	12	3.40
gpt-5.5	822	0.822	53	16.10

Porcentaje de acierto por umbrales de error

Modelo	<=10%	<=20%	<=30%	<=50%
gpt-4o	5.60	26.30	49.10	80.90
gpt-4o-mini	1.20	8.00	18.30	43.10
gpt-5	5.10	23.40	48.40	87.10
gpt-5.1	7.70	35.80	64.30	93.70
gpt-5.2	1.40	8.40	22.80	54.10
gpt-5.4	2.00	10.50	24.10	59.80
gpt-5.5	2.50	13.30	26.90	62.90

Graficos principales - Con ruido

Distribucion del error cromatico por modelo

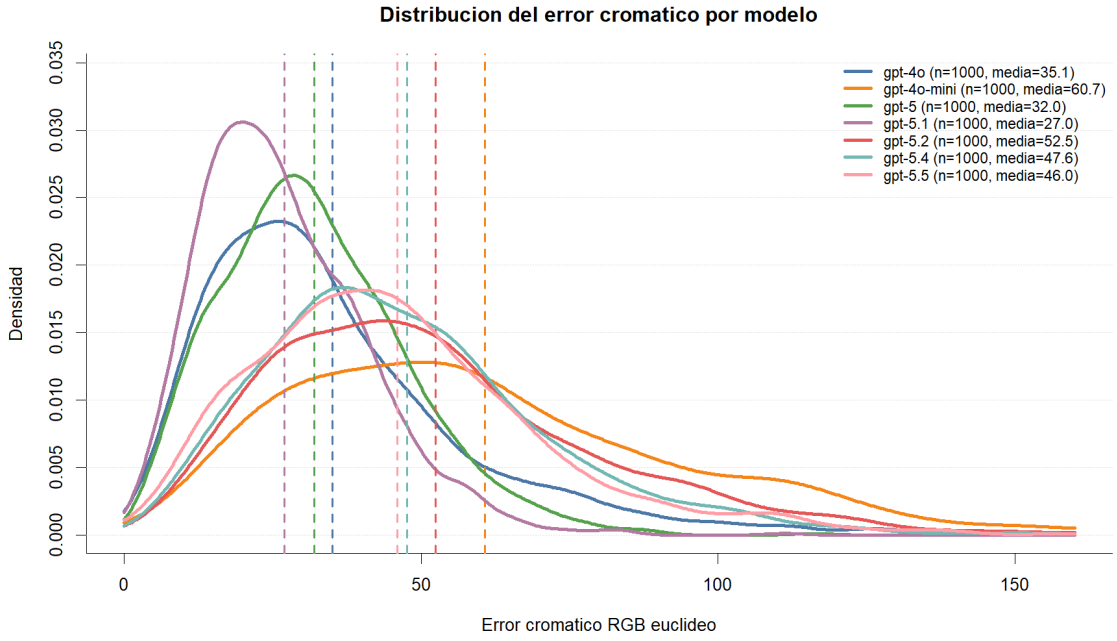

Violin + boxplot del error

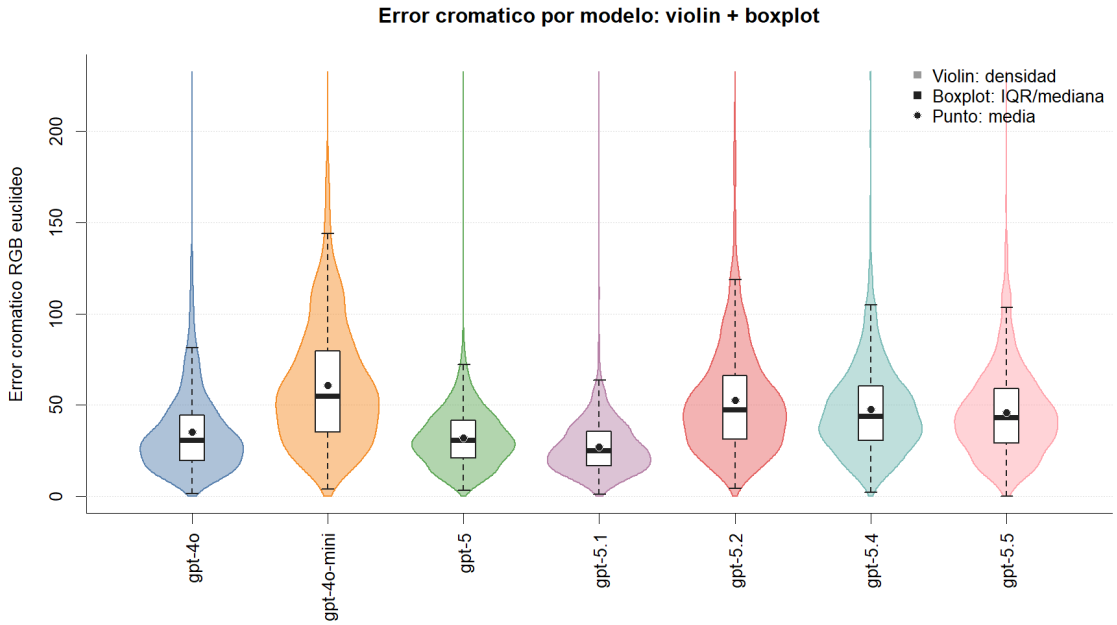

Chroma - Con ruido

Correlacion lineal entre error y chroma

Modelo	n	corr(error, chroma)
gpt-4o	1000	0.425
gpt-4o-mini	1000	0.273
gpt-5	1000	0.336
gpt-5.1	1000	0.244
gpt-5.2	1000	0.064
gpt-5.4	1000	-0.036
gpt-5.5	1000	0.357

Error medio por bucket de chroma

Modelo	Q1	Q2	Q3	Q4
gpt-4o	24.14	30.29	35.88	50.15
gpt-4o-mini	47.25	57.63	67.59	70.38
gpt-5	24.75	31.43	33.94	38.03
gpt-5.1	23.10	26.65	26.40	31.68
gpt-5.2	50.19	50.49	53.97	55.27
gpt-5.4	47.97	49.42	47.32	45.76
gpt-5.5	34.80	40.48	49.76	58.84

Grafico error vs chroma

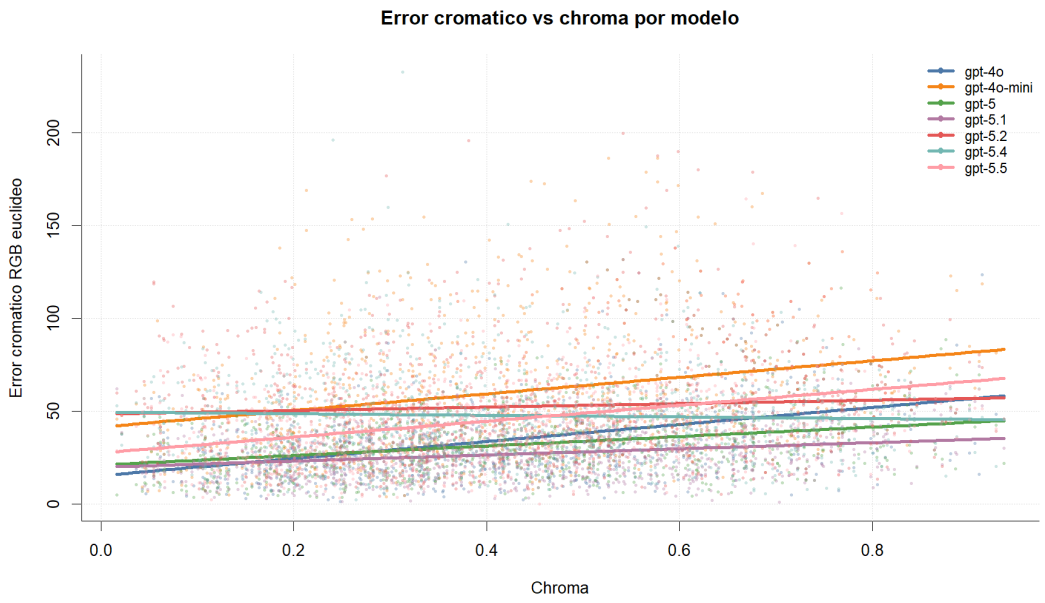

Respuestas repetidas - Con ruido

Concentracion de respuestas repetidas

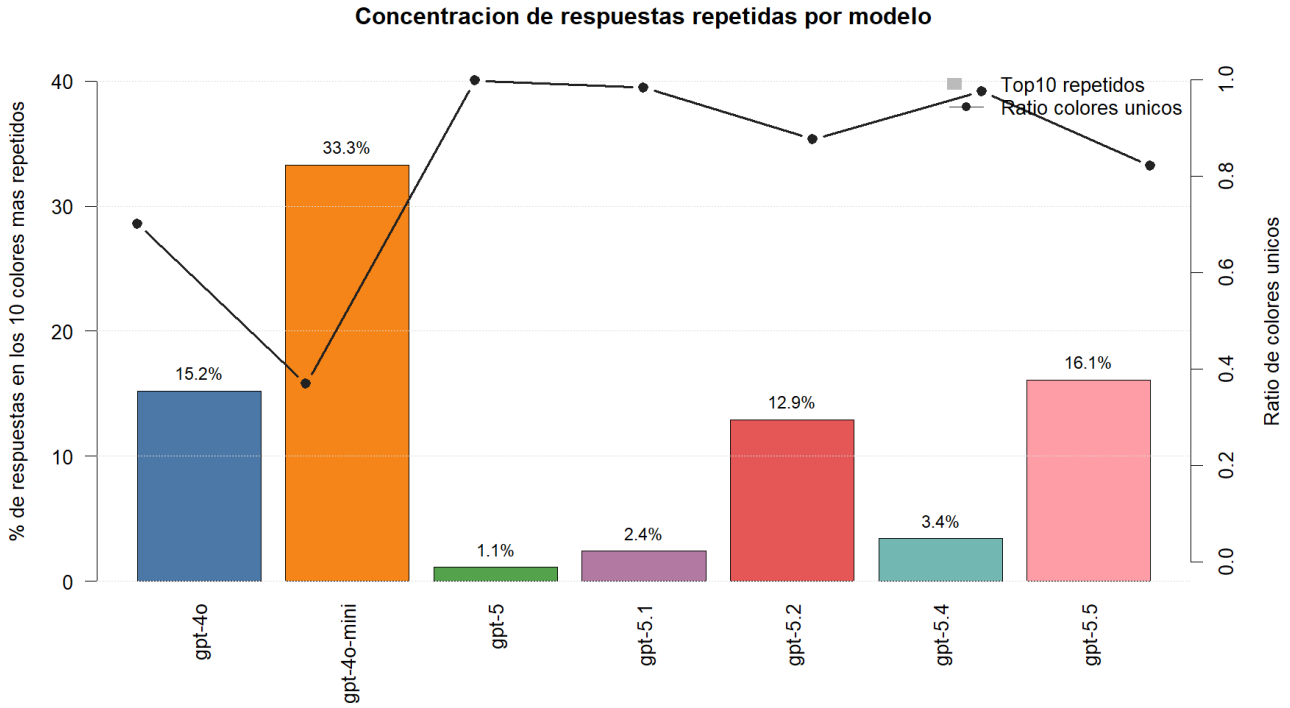

2. Resultados - Sin ruido

Dataset combinado: 7000 respuestas, 1000 imagenes y 7 modelos. Mejor error medio: gpt-5.5 (12.07). Modelo con mayor lazy response: gpt-4o-mini (26.4% en top 10 colores repetidos).

Descriptiva del error cromatico

Modelo	n	Media	Mediana	SD
gpt-4o	1000	23.60	18.17	17.65
gpt-4o-mini	1000	49.67	41.93	32.83
gpt-5	1000	13.46	11.36	8.91
gpt-5.1	1000	16.20	13.19	11.56
gpt-5.2	1000	17.12	13.27	16.26
gpt-5.4	1000	14.29	12.61	8.84
gpt-5.5	1000	12.07	10.49	7.41

Lazy response

Modelo	Unicos	Ratio	Max rep.	Top10 %
gpt-4o	785	0.785	21	10.00
gpt-4o-mini	418	0.418	74	26.40
gpt-5	988	0.988	4	2.20
gpt-5.1	977	0.977	6	2.90
gpt-5.2	962	0.962	22	4.60
gpt-5.4	994	0.994	3	1.60
gpt-5.5	999	0.999	2	1.10

Porcentaje de acierto por umbrales de error

Modelo	<=10%	<=20%	<=30%	<=50%
gpt-4o	21.00	54.50	73.90	90.70
gpt-4o-mini	4.90	18.70	33.50	60.00
gpt-5	42.90	80.00	94.80	99.60
gpt-5.1	35.60	72.60	87.30	98.30
gpt-5.2	33.60	75.00	89.80	96.40
gpt-5.4	36.80	77.80	93.60	99.90
gpt-5.5	46.00	85.70	97.30	100.00

Graficos principales - Sin ruido

Distribucion del error cromatico por modelo

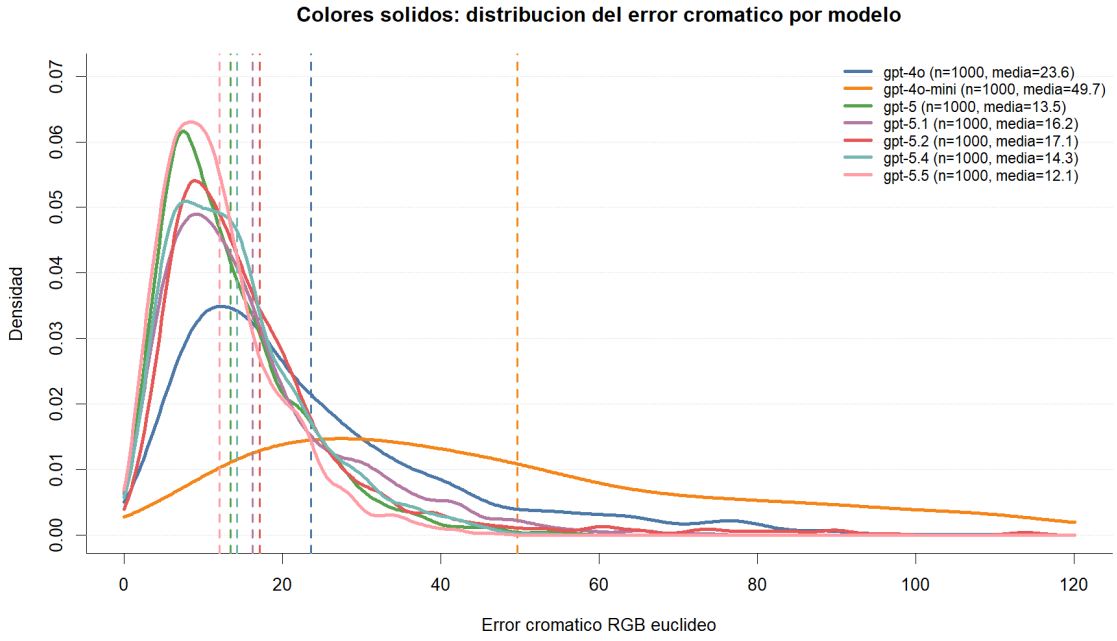

Violin + boxplot del error

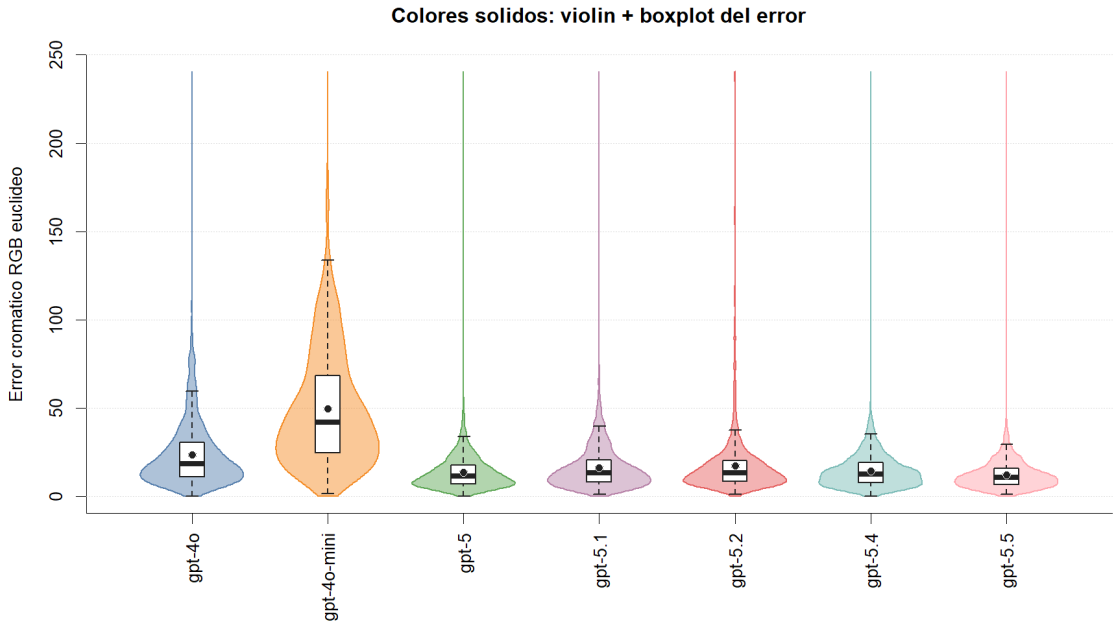

Chroma - Sin ruido

Correlacion lineal entre error y chroma

Modelo	n	corr(error, chroma)
gpt-4o	1000	0.503
gpt-4o-mini	1000	0.400
gpt-5	1000	0.523
gpt-5.1	1000	0.573
gpt-5.2	1000	0.352
gpt-5.4	1000	0.360
gpt-5.5	1000	0.222

Error medio por bucket de chroma

Modelo	Q1	Q2	Q3	Q4
gpt-4o	14.45	17.28	24.24	38.41
gpt-4o-mini	33.42	43.91	52.05	69.31
gpt-5	8.05	11.68	13.71	20.39
gpt-5.1	9.89	12.74	15.00	27.16
gpt-5.2	12.24	11.93	16.49	27.80
gpt-5.4	10.77	12.84	14.13	19.41
gpt-5.5	9.64	12.80	11.34	14.52

Grafico error vs chroma

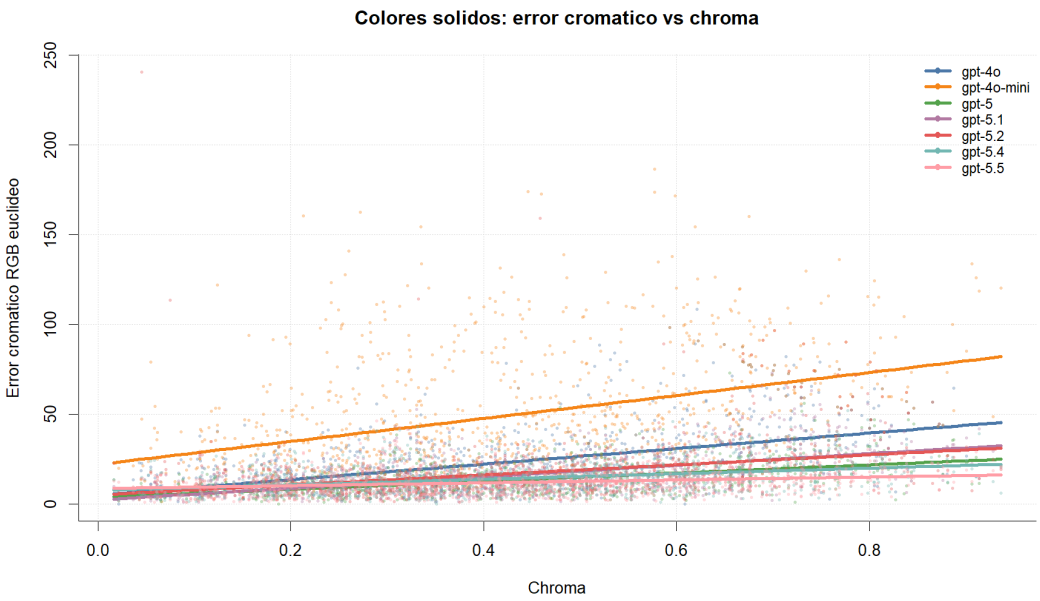

Respuestas repetidas - Sin ruido

Concentracion de respuestas repetidas

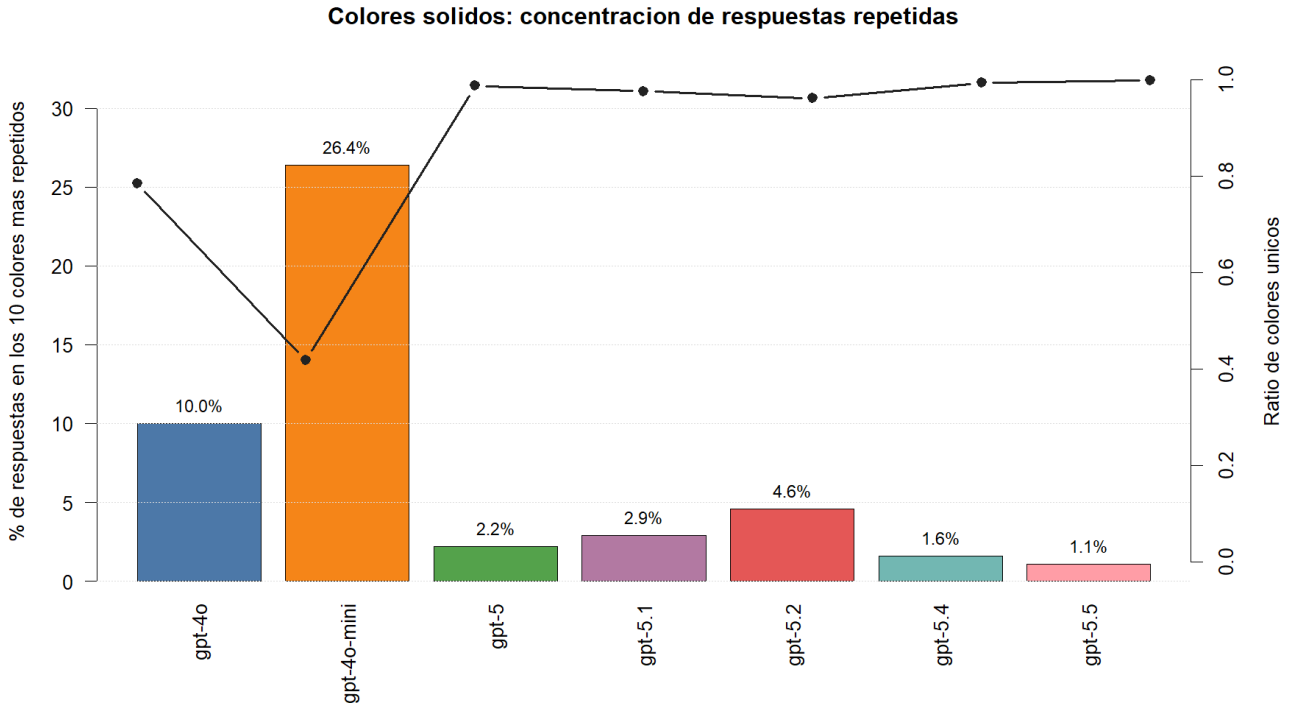

4. Comparacion final

La tabla muestra cuanto baja el error medio al pasar de imagenes con ruido a colores solidos sin ruido. La columna de mejora es: media_con_ruido - media_sin_ruido.

Modelo	Media con ruido	Media sin ruido	Mejora sin ruido
gpt-4o	35.11	23.60	11.52
gpt-4o-mini	60.71	49.67	11.04
gpt-5	32.04	13.46	18.58
gpt-5.1	26.96	16.20	10.76
gpt-5.2	52.48	17.12	35.37
gpt-5.4	47.62	14.29	33.33
gpt-5.5	45.97	12.07	33.90

Conclusiones principales

1. El ruido empeora el error en todos los modelos, pero no por igual.

2. En la condicion con ruido, gpt-5.1 obtiene el menor error medio y una baja concentracion de respuestas repetidas.

3. En la condicion sin ruido, gpt-5.5 obtiene el menor error medio y tambien el menor lazy response entre los modelos comparados.

4. gpt-4o-mini es el modelo con mas lazy response en ambas condiciones.

5. El analisis por buckets de chroma muestra que los colores de chroma alto suelen ser mas dificiles, especialmente sin ruido.